

ממן 21 כריית מידעדבורה קלטי 2148040721. הגדרת הבעיה והכנת הנתונים.א. מטרות כריית המידע, הנחות והפשטות

- **מטרה:** לבנות מודל שיודע לסווג אם לנבדק יש סרטן חלל הפה על סמך המאפיינים האישיים והרפואיים שלו. בנוסף, אני רוצה לראות אילו גורמים (כמו עישון או גיל) הם הכי משמעותיים לחיזוי.
- **הנחות והפשטות:** אני מניחה שהנתונים באקסל אמינים ומייצגים מצבים אמיתיים, ושאינן הטיות קריטיות בדרך שבה אספו את המידע מהנבדקים.

ב. הגדרת הנתונים הסופיים בהם השתמשת

שם התכונה	תיאור התכונה	סוג הנתון	תחומי ערכים
Country	מדינת המקור של הנבדק	קטגוריאל	17 מדינות שונות
Age	גיל הנבדק	מספרי	15 - 101
Gender	מין הנבדק	קטגוריאל	Female, Male
Tobacco Use	שימוש במוצרי טבק	קטגוריאל	Yes, No
Alcohol Consumption	צריכת אלכוהול	קטגוריאל	Yes, No
HPV Infection	הימצאות נגיף הפפילומה	קטגוריאל	Yes, No
Betel Quid Use	לעיסת אגוז בטל	קטגוריאל	Yes, No
Chronic Sun Exposure	חשיפה כרונית לשמש	קטגוריאל	Yes, No
Poor Oral Hygiene	היגיינת פה לקויה	קטגוריאל	Yes, No
Diet	רמת צריכת פירות וירקות	קטגוריאל	Low, Moderate, High
Family History	היסטוריה משפחתית של סרטן	קטגוריאל	Yes, No
Compromised Immune System	מערכת חיסונית מוחלשת	קטגוריאל	Yes, No
Oral Lesions	קיום נגעים בחלל הפה	קטגוריאל	Yes, No
Unexplained Bleeding	דימום לא מוסבר בפה	קטגוריאל	Yes, No
Difficulty Swallowing	קשיי בליעה	קטגוריאל	Yes, No
White/Red Patches	כתמים לבנים או אדומים בפה	קטגוריאל	Yes, No
Early Diagnosis	האם בוצע אבחון מוקדם	קטגוריאל	Yes, No
Oral Cancer (Diagnosis)	אבחנה: סרטן חלל הפה	קטגוריאל	Yes, No

הסברים מפורטים על סיבת הסרת העמודות נדון בהמשך בסעיף ה'

ג. הגדרת שלבי ה-KDD-

1. **איסוף ושמירת נתונים ומידע** – בשלב זה נבחר מערך הנתונים עליו נעבוד, הכולל גורמי סיכון קליניים לאבחון סרטן חלל הפה. משיקולי יעילות ואיכות המידע, נבחר סט נתונים רחב המאפשר למידה מעמיקה של המודלים.
2. **ניקוי הנתונים** – שלב זה כולל איתור רשומות בעלות ערכים לא הגיוניים או חריגים. נחליט עבור כל חריגה האם לתקן את הערך או להשמיט את הרשומה כליל כדי למנוע הטיה של התוצאות.
3. **ביצוע טרנספורמציה על המידע** – בשלב זה נבחן האם ניתן לגזור מידע חדש מתוך הנתונים הקיימים (הנדסת תכונות) שיכול לסייע לדיוק המודל, ונבצע פעולות של נרמול ודיסקרטיזציה לפי הצורך.
4. **בחירת שיטות לכריית המידע** – בהתאם למטרת הפרויקט, נבחר בשיטת ה-Classification (סיווג). מתוך האפשרויות הקיימות, נתמקד באלגוריתמים ממשפחת עצי ההחלטה המאמינים לניתוח גורמי סיכון רפואיים.
5. **ביצוע דיסקרטיזציה וסיווג הנתונים** – ביצוע הכנה סופית של המידע והתאמתו לאלגוריתמים שנבחרו, תוך שמירה על איכות הנתונים והמשתנים שנמצאו כרלוונטיים ביותר.
6. **הרצת שיטות לכריית המידע** – הפעלת המודלים שנבחרו על מערך הנתונים המעובד לשם יצירת מודל חיזוי ראשוני.
7. **ניתוח התוצאות** – הערכת ביצועי המודלים השונים על פי מדדי איכות מקובלים. פירוט מלא מופיע בסעיף ה' של העבודה.

ד. סקירה השוואתית לחלופות לביצוע כריית מידע

1. עץ החלטה ID3

- אלגוריתם בסיסי לבניית עצי החלטה שבוחר בכל שלב את התכונה המפצלת לפי מדד רווח מידע (Information Gain) המבוסס על אנטרופיה.
- יתרונות:** האלגוריתם פשוט מאוד להבנה וליישום, והוא נחשב ליעיל ומהיר מבחינת זמן ריצה.
- חסרונות:** המדד שלו נוטה להעדפת תכונות בעלות ערכים רבים, הוא אינו יודע להתמודד עם ערכים חסרים או רציפים ללא עיבוד מקדים, ולעיתים קרובות נוצרת בעיה של התאמת יתר (Overfitting).

2. עץ החלטה C4.5

- שיטה זו מהווה שיפור של ה-ID3 ומנסה להתגבר על חסרונותיו באמצעות שימוש במדד יחס הרווח (Gain Ratio) במקום רווח המידע המקורי.
- יתרונות:** יודע לטפל בצורה טובה בערכים חסרים וברצפי נתונים, וכולל מנגנון של גיזום ענפים שעוזר למנוע בנייה של עץ מורכב מדי שסובל מהתאמת יתר.
- חסרונות:** האלגוריתם מורכב יותר לביצוע ועלול לדרוש יותר משאבי זיכרון בעבודה מול קבצי נתונים גדולים במיוחד.

3. עץ החלטה CART

- אלגוריתם המבוסס על מדד ג'יני (Gini Index) לביצוע החלוקה. בניגוד לשיטות אחרות, הוא מבצע תמיד פיצולים בינאריים, כלומר לכל צומת בעץ יש בדיוק שני בנים.

יתרונות: מתאים מאוד למצבים שבהם נדרש פלט של כן או לא, והוא נוטה לייצר מודלים מדויקים וקומפקטיים יותר בהשוואה לעצים אחרים.

חסרונות: הוא רגיש לשינויים בנתוני האימון, כך ששינוי קטן בנתונים עלול לשנות משמעותית את כל מבנה העץ.

4. אלגוריתם AdaBoost

טכניקה המשלבת מספר רב של מודלים פשוטים וחלשים ליצירת מודל אחד חזק. היא עושה זאת על ידי מתן משקל גבוה יותר לדגימות שהמודלים הקודמים התקשו לסווג נכון.

יתרונות: משפר משמעותית את רמת הדיוק של החיזוי ומצמצם הטיות במודל הסופי.

חסרונות: רגיש מאוד לנתונים "רועשים" ולערכים חריגים שעלולים לקבל משקל יתר ולפגוע בביצועי המודל הכללי.

ה. הכנת הנתונים וטיובם

בשלב זה ביצעתי סדרה של פעולות כדי להבטיח שאיכות הנתונים תאפשר בניית מודל אמין ומהימן .

1. הסרת תכונות וטיפול ב"זליגת מידע" (Data Leakage)

הסרתי מספר עמודות ממערך הנתונים כדי למנוע הטיות :

- **עמודת ה-ID**-הוסרה מכיוון שהיא מהווה מזהה טכני בלבד ואינה תורמת לחיזוי רפואי .

- **מניעת זליגת מידע: (Data Leakage)** הסרתי את העמודות

Tumor size, Cancer stage, Treatment type, Survival Rate, Cost of Treatment, Economic burden.

- הבחירה להסיר נובעת מכך שהן מייצגות נתונים שקיימים **רק לאחר** שכבר נקבעה אבחנה. מכיוון שמטרת הפרויקט היא לזהות את המחלה על פי סימפטומים מוקדמים, הכללת נתונים אלו תביא לדיוק מזויף במודל .

2. טיפול בערכים כפולים וחסרים


- **ערכים חסרים ושגויים**: בחינה של מערך הנתונים העלתה כי הוא נקי לחלוטין מערכים חסרים (Missing Values) או ערכים שגויים בולטים לעין, ולכן לא נדרש ביצעו של השלמת נתונים. (Imputation)

- **הסרת כפילויות**: ביצעתי הסרה של ערכים כפולים. בשלב הראשון הסרתי 2,739 שורות שהיו כפילויות מלאות במערך הנתונים כדי למנוע הטיות סטטיסטיות, בשלב השני ביצעתי ניקוי מעמיק יותר של ערכים סותרים, מה שהסיר עוד 2,381 שורות והביא אותי למערך נתונים סופי ונקי של 79,802 רשומות.




3. תצוגה גרפית של הנתונים (Visualizations)

לפני הרצת המודלים, ביצעתי סקירה ויזואלית של התפלגות המשתנים בתוכנת WEKA. ניתן לראות שהנתונים מאוזנים יחסית מבחינת עמודת המטרה, (Diagnosis) וכי רוב המשתנים הקטגוריאליים מחולקים בצורה המאפשרת למודל ללמוד תבניות .




4.המרת נתונים (Data Transformation) ודיסקרטיזציה

התכונה **Age** (גיל) היא תכונה מספרית רציפה. כדי להתאים אותה לאלגוריתמי סיווג כמו ID3, ביצעתי פעולת **דיסקרטיזציה**. חילקתי את הגילאים ל **5-סלים (Bins) שווי רוחב** ב WEKA. פעולה זו הופכת את הגיל הרציף לקבוצות גיל, מה שמפשט את המודל ומונע ממנו לנסות ללמוד גילאים ספציפיים מדי. (Overfitting).



5.בחירת תכונות (Feature Selection)

בביצוע בדיקת חשיבות תכונות, (InfoGainAttributeEval), נמצא כי התכונה **Country** (מדינה) היא המנבאת החזקה ביותר במערך הנתונים הנוכחי, ומיד אחריה תכונת הגיל. שאר התכונות הראו ערכי רווח מידע נמוכים יחסית, דבר שמעיד על מורכבות הבעיה ועל הצורך במודלים חזקים יותר.



2. סיווג

- א. בחרתי להשתמש באלגוריתם ID3 מכיוון שהוא מהווה את הבסיס הקלאסי לעצי החלטה ומתאים מאוד למערכי נתונים המורכבים ברובם ממשתנים קטגוריאליים, כפי שקיים בפרויקט שלי עם משתנים כמו עישון, צריכת אלכוהול וזיהום HPV. האלגוריתם משתמש במדד רווח מידע המבוסס על אנטרופיה כדי למצוא את גורמי הסיכון המשמעותיים ביותר בכל שלב בבניית העץ. בחרתי בו משום שהוא נחשב לשיטה יעילה ומהירה מאוד המאפשרת להבין את הלוגיקה מאחורי כל חיזוי רפואי בצורה של עץ החלטה פשוט וקריא, דבר שחיוני כאשר מנסים להסביר אבחנה של סרטן חלל הפה על סמך סימפטומים והרגלים.
- בנוסף, בחרתי להשתמש באלגוריתם J48 המהווה את הגרסה המשופרת של עץ ההחלטה בתוכנת ווקה, כדי לבחון מודל מתקדם יותר שמסוגל להתמודד עם המגבלות של ID3. בחרתי בו כיוון שהוא משתמש במדד יחס הרווח שמונע הטיה לטובת משתנים בעלי ערכים רבים, מה שקריטי עבור משתנה המדינה הקיים במערך הנתונים שלי, ובנוסף הוא כולל מנגנוני גיזום שעוזרים למנוע התאמת יתר במערך נתונים כה גדול הכולל עשרות אלפי רשומות. היכולת שלו לטפל בצורה טובה יותר בערכים רציפים סייעה לי לשלב את משתנה הגיל בתוך מודל החיזוי בצורה אופטימלית גם לאחר תהליך הדיסקרטיזציה שביצעתי.
- ב.

1. ID3 Algorithm

Algorithm ID3 (Examples, Target_Attribute, Attributes)

1. Create a Root node for the tree.
2. If all Examples are positive, return Root with label = Yes.
3. If all Examples are negative, return Root with label = No.
4. If Attributes list is empty, return Root with label = most common value of Target_Attribute.
5. Otherwise:
 - Calculate Information Gain for every attribute in the list.
 - Select the attribute with the highest Information Gain.
 - Set this attribute as the decision attribute for Root.
 - For each possible value of this attribute:
 - Add a new branch below Root for that value.
 - Create a Subset of Examples that have that specific value.
 - If Subset is empty, add a leaf node with the most common value of Target_Attribute.
 - Else, add a subtree by calling ID3 recursively for the Subset.

6. Return the Root node.

2. J48 Algorithm (C4.5)

Algorithm J48 (Dataset)

1. If all instances belong to the same class or attribute list is empty, create a leaf node with the majority class.

2. For each attribute in the dataset:

-- Calculate the Gain Ratio.

-- For continuous attributes like Age, find the best split point.

3. Select the attribute with the highest Gain Ratio as the splitting node.

4. Create a decision node and split the data into subsets based on its values.

5. For each subset, call the J48 function recursively to build branches.

Post-Pruning Phase:

-- After building the tree, traverse from bottom to top.

-- If removing a branch .

. 6 and replacing it with a leaf reduces the error rate, remove the branch .

7. Return the final pruned tree.

ג.

תוצאות אלגוריתם ID3 האלגוריתם הורץ בחלוקה של 66% לטובת אימון המודל ו-34% לבחינתו .

- **דיוק כללי: (Correctly Classified Instances)** המודל סיווג נכון 49.64% מהמקרים, שהם 13,469 רשומות מתוך קבוצת המבחן .

- **מדד Precision:** הממוצע המשוקלל עומד על 0.498, נתון המצביע על יכולת נמוכה מאוד של המודל לדייק בזיהוי המקרים החיוביים מתוך כלל המקרים שסווגו ככאלו .

- **מדד TP Rate:** הממוצע עומד על 0.499, מה שמעיד על כך שהמודל מצליח לזהות רק כמחצית מהמקרים שבאמת סובלים מהמחלה .

מטריצת בלבול (Confusion Matrix) עבור ID3: סיווג נכון כ "No"-(שלילי): 7,402


רשומות.

- סיווג שגוי כ "Yes"-(חיובי כוזב): 6,139 רשומות.

- סיווג שגוי כ "No"-(שלילי כוזב): 7,408 רשומות.

- סיווג נכון כ "Yes"-(חיובי): 6,067 רשומות.

תוצאות הרצת אלגוריתם ID3 ומטריצת הבלבול.



תוצאות אלגוריתם J48 האלגוריתם הורץ בשיטת Percentage Split של 80% לאימון ו-20% לבדיקה, תוך שימוש במנגנון הגיזום המובנה.

- **דיוק כללי: (Correctly Classified Instances)** המודל השיג רמת דיוק של 50.05%, שהם 7,989 רשומות מתוך קבוצת המבחן.
- **מדד Kappa:** הערך שהתקבל הוא 0.0012. נתון זה קרוב מאוד לאפס ומצביע על כך שהתוצאות שהתקבלו כמעט ואינן שונות מתוצאות שהיו מתקבלות על ידי ניחוש אקראי לחלוטין.
- **ROC Area:** הערך עומד על 0.502. במדד זה, ערך של 0.5 נחשב לניבוי חסר תועלת לחלוטין, מה שמעיד כי המודל לא הצליח ללמוד תבניות מנבאות משמעותיות מתוך הנתונים.

מטריצת בלבול (Confusion Matrix) עבור J48: כאן כדאי להדביק את תמונת המסך של תוצאות ה-J48 ושל העץ הוויזואלי (

- סיווג נכון כ "No"-(שלילי): 4,076 רשומות.
- סיווג שגוי כ "Yes"-(חיובי כוזב): 3,879 רשומות.
- סיווג שגוי כ "No"-(שלילי כוזב): 4,092 רשומות.
- סיווג נכון כ "Yes"-(חיובי): 3,913 רשומות.

סיכום ביניים: ניתן לראות כי שני האלגוריתמים הציגו תוצאות דומות ודיוק הנע סביב 50%. נתון זה מעיד על קושי מהותי ביצירת הפרדה בין הקבוצות במערך הנתונים הנוכחי, ככל הנראה בשל קשר חלש בין הסימפטומים המתוארים לבין האבחנה הסופית.

לאחר הרצת שני המודלים, ביצעתי הערכה של רמת הדיוק שלהם על סמך המדדים שהתקבלו בתוכנת WEKA. באופן כללי, ניתן לראות כי שני האלגוריתמים הציגו ביצועים דומים מאוד, אשר נחשבים לנמוכים במיוחד בתחום כריית המידע.

הערכת אלגוריתם ID3 רמת הדיוק הכללית של האלגוריתם עומדת על 49.64%. מדד זה מעיד על כך שהמודל מצליח לסווג נכון רק כמחצית מהמקרים, נתון הדומה להטלת מטבע אקראית. כאשר בוחנים את מדדי ה-Precision-Recall, וה-Roc-Area, רואים ערכים הנעים סביב 0.5, מה שמצביע על כך שהמודל אינו מצליח לייצר הפרדה אמיתית בין נבדקים בריאים לנבדקים חולים על סמך התכונות הקיימות.

הערכת אלגוריתם J48 האלגוריתם הציג דיוק כללי של 50.05%. למרות שזהו שיפור מזערי לעומת ה-ID3, המדדים המשלימים מראים שהמודל אינו אמין:

- **מדד Kappa:** הערך שהתקבל (0.0012) קרוב מאוד לאפס, מה שמאשש את הקביעה שהסיווג שביצע המודל הוא מקרי לחלוטין ואינו מבוסס על למידה אמיתית של תבניות בנתונים.
- **מדד ROC Area:** הערך 0.502 נחשב לערך סף מינימלי בביצועי מסווגים. משמעותו היא שלמודל אין יכולת הבחנה בין המחלקות השונות (חולה/בריא), והוא אינו יעיל לשימוש קליני במצבו הנוכחי.

סיכום והשוואה השוואת התוצאות מראה כי השיפורים המובנים באלגוריתם J48, כגון מנגנון הגיזום והטיפול בערכים רציפים, לא הצליחו להעלות את רמת הדיוק באופן משמעותי במערך נתונים זה. נראה כי הקשר בין המשתנים שהוגדרו כסימפטומים לבין תוצאת האבחנה הסופית חלש מאוד, דבר המקשה על עצי ההחלטה למצוא חוקיות ברורה.

ה. ניתוח השוואתי, מסקנות והצעות לשיפור

בסעיף זה אנתח את ממצאי המחקר ואציג מסקנות הנובעות מההבדלים בין האלגוריתמים ומאיכות הנתונים.

ניתוח השוואתי בין ID3 ל J48 – למרות שאלגוריתם J48 כולל מנגנונים מתקדמים של גיזום וטיפול בערכים רציפים, הדיוק שהתקבל (50.05%) היה כמעט זהה לזה של ID3 (49.64%). המסקנה היא שבמערך נתונים זה, מורכבות המודל לא תרמה לשיפור החיזוי. שניהם הציגו מדד Kappa קרוב לאפס ומדד ROC של כ-0.5, מה שמעיד על כך שהמודלים לא הצליחו ללמוד חוקיות ממשיית והתוצאות דומות לניחוש אקראי.

מסקנות לגבי משתני הניבוי מבדיקת חשיבות התכונות שביצעתי (InfoGain), עולה כי המשתנה המשמעותי ביותר הוא המדינה (Country) בעוד ששאר המשתנים הרפואיים וההתנהגותיים הראו תרומה אפסית לחיזוי. עובדה זו מסבירה את הדיוק הנמוך; נראה כי במערך הנתונים הנוכחי, המאפיינים הקליניים אינם מספקים אינפורמציה מספקת כדי להבדיל בין חולה לבריא.

חשיבות טיוב הנתונים ומניעת זליגת מידע במהלך העבודה הקפדתי להסיר משתנים כמו "גודל הגידול" ו"סוג הטיפול". כפי שציינתי בהכנת הנתונים, הכללתם הייתה יוצרת "זליגת מידע" (Data Leakage) "ודיוק מזויף", שכן אלו נתונים שמתגלים רק לאחר שהאבחנה כבר בוצעה. החלטה זו אמנם הובילה לדיוק נמוך יותר, אך היא הפכה את המודל לאמין ורלוונטי יותר למטרת הפרויקט: אבחון מוקדם על סמך סימפטומים בלבד.

הצעות לשיפור המודל

1. **שיפור איכות הנתונים:** מומלץ לאסוף נתונים קליניים מעמיקים יותר (כמו בדיקות מעבדה או ביופסיות) שהקשר שלהם לסרטן חלל הפה מבוסס יותר מבחינה רפואית.
2. **איזון נתונים (Balancing):** כדאי לבדוק האם קיים חוסר איזון בין כמות החולים לבריאים במערך המקורי ולהשתמש בטכניקות דגימה (Oversampling) כדי לחזק את הלמידה של המודל.
3. **מודלים משולבים:** מומלץ לנסות אלגוריתמים מסוג Ensemble, כגון Random Forest, המסוגלים לשלב מספר רב של עצים ולמצוא קשרים מורכבים יותר בין התכונות.

Weka Explorer

Preprocess Classify Cluster Associate **Select attributes** Visualize

Attribute Evaluator

Choose **CfsSubsetEval** P 1 E 1

Search Method

Choose **BestFirst -D 1 -N 5**

Attribute Selection Mode

☒ Use full training set

☐ Cross-validation Folds 10 Seed 1

(Nom) Oral Cancer (Diagnosis) v

Start Stop

Result list (right-click for options)

170232 - Ranker + InfoGainAttributeEval

170526 - BestFirst + CfsSubsetEval

Attribute selection output

Alcohol Consumption
 HPV Infection
 Betel Quid Use
 Chronic Sun Exposure
 Poor Oral Hygiene
 Diet (Fruits & Vegetables Intake)
 Family History of Cancer
 Compromised Immune System
 Oral Lesions
 Unexplained Bleeding
 Difficulty Swallowing
 White or Red Patches in Mouth
 Early Diagnosis
 Oral Cancer (Diagnosis)

Evaluation mode: evaluate on all training data

--- Attribute Selection on all input data ---

Search Method:
 Best first.
 Start set: no attributes
 Search direction: forward
 Stale search after 5 node expansions
 Total number of subsets evaluated: 87
 Size of best subset found: 0

Attribute subset evaluator (supervised, Class (nominal): 18 Oral Cancer (Diagnosis)):
 CFS Subset Evaluator
 Including locally predictive attributes

Selected attributes: 1 : 1
 Country

Time taken to build model: 0.51 seconds

=== Evaluation on test split ===

Time taken to test model on test split: 0.08 seconds

=== Summary ===

Correctly Classified Instances	13469	49.6407 %
Incorrectly Classified Instances	13547	49.9281 %
Kappa statistic	-0.0031	
Mean absolute error	0.5008	
Root mean squared error	0.6719	
Relative absolute error	100.6023 %	
Root relative squared error	134.6769 %	
Unclassified Instances	117	0.4312 %
Total Number of Instances	27133	

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	FRC Area	Class
	0.547	0.550	0.500	0.547	0.522	-0.003	0.499	0.501	No
	0.450	0.453	0.497	0.450	0.472	-0.003	0.499	0.498	Yes
Weighted Avg.	0.499	0.502	0.498	0.499	0.497	-0.003	0.499	0.499	

=== Confusion Matrix ===

a	b	<-- classified as
7402	6139	a = No
7408	6067	b = Yes