

1. חוקי הקשר

א. בחרתי להשתמש באלגוריתם Apriori, המשמש למציאת קשרים ודפוסים בין מאפיינים שונים במאגר נתונים. האלגוריתם מאתר צירופים של ערכים המופיעים יחד לעיתים קרובות, ועל בסיסם יוצר חוקי קשר המתארים את היחסים ביניהם. עבור כל חוק מחושבים מדדים כגון Support, Confidence, Lift-המאפשרים להעריך את עוצמת הקשר ואת מידת האמינות שלו.

האלגוריתם מתאים למאגר הנתונים שבחרתי, הכולל מאפיינים כמו גיל, מין, עישון, צריכת אלכוהול, זיהום HPV והיגיינת פה. מטרת השימוש בו היא לזהות דפוסים וקשרים אפשריים בין גורמי סיכון שונים לבין הופעת סרטן הפה. בנוסף Apriori, הוא אלגוריתם ללמידה בלתי מונחית, ולכן אינו מחייב הגדרה של משתנה יעד מראש. יכולתו להפיק חוקים ברורים וקלים להבנה הופכת אותו לכלי מתאים במיוחד לניתוח נתונים בתחומי הבריאות והרפואה.

הכנת הנתונים: לפני הרצת אלגוריתם Apriori בוצע שלב של הכנת הנתונים. מכיוון שהאלגוריתם עובד עם נתונים קטגוריאליים, היה צורך להמיר את משתנה הגיל (Age), שהוא משתנה מספרי רציף, לקבוצות גיל. לשם כך בוצעה חלוקה של הגיל לשתי קבוצות בלבד. (Bins = 2) הסיבה לכך היא שכאשר מחלקים את הנתונים ליותר מדי קבוצות, כל קבוצה מכילה פחות רשומות, ולכן ייתכן שלא תעמוד בערך ה-Support המינימלי שנבחר (40%). החלוקה לשתי קבוצות אפשרה לשמור על מספיק נתונים בכל קבוצה וכך לכלול את משתנה הגיל בתהליך מציאת חוקי הקשר.

ב. מציאת קבוצות תדירות באמצעות אלגוריתם Apriori, על פי דרישות השאלה השתמשתי בפרמטרים הבאים:

Min Support = 40% תמיכה מינימלית .

Min Confidence = 60% אמון מינימלי.

משמעות הדבר היא שקבוצת פריטים תיחשב לקבוצה תדירה רק אם היא מופיעה בלפחות 40% מהרשומות במאגר הנתונים.

האלגוריתם פועל באופן הדרגתי: תחילה מאתר קבוצות תדירות בגודל 1, (L1) לאחר מכן קבוצות בגודל 2, (L2) ובהמשך קבוצות גדולות יותר. במקרה זה נמצאו קבוצות תדירות בגודל 1 ובגודל 2 בלבד.

קבוצות תדירות בגודל 1 (L1):

נמצאו 8 פריטים בודדים שעברו את סף התמיכה של 40%:

Gender = Male 1.

- Tobacco Use = Yes .2
- Betel Quid Use = No .3
- Chronic Sun Exposure = No .4
- Family History of Cancer = No .5
- Compromised Immune System = No .6
- Unexplained Bleeding = No .7
- Difficulty Swallowing = No .8

קבוצות תדירות בגודל 2 (L2):

נמצאו 7 זוגות של פריטים שהופיעו יחד ועברו את סף התמיכה של 40%:

- Tobacco Use = Yes , Family History of Cancer = No .1
- Tobacco Use = Yes , Compromised Immune System = No .2
- Chronic Sun Exposure = No , Family History of Cancer = No .3
- Chronic Sun Exposure = No , Compromised Immune System = No .4
- Family History of Cancer = No , Compromised Immune System = No .5
- Family History of Cancer = No , Unexplained Bleeding = No .6
- Compromised Immune System = No , Unexplained Bleeding = No .7

Generated sets of large itemsets:

Size of set of large itemsets L(1): 8

Large Itemsets L(1):

Gender=Male 55989
Tobacco Use=Yes 63152
Betel Quid Use=No 56612
Chronic Sun Exposure=No 63292
Family History of Cancer=No 71472
Compromised Immune System=No 71328
Unexplained Bleeding=No 63132
Difficulty Swallowing=No 59181

Size of set of large itemsets L(2): 7

Large Itemsets L(2):

Tobacco Use=Yes Family History of Cancer=No 56509
Tobacco Use=Yes Compromised Immune System=No 56396
Chronic Sun Exposure=No Family History of Cancer=No 56636
Chronic Sun Exposure=No Compromised Immune System=No 56516
Family History of Cancer=No Compromised Immune System=No 63831
Family History of Cancer=No Unexplained Bleeding=No 56491
Compromised Immune System=No Unexplained Bleeding=No 56358

ג. אחרי שהאלגוריתם מצא את הקבוצות התדירות שעברו את רף התמיכה של 40%, הוא ייצר את חוקי ההקשר הכי חזקים שעומדים ברף האמון המינימלי של 60%.

עבור כל חוק שנוצר, התוכנה מחשבת את רמת האמינות שלו ואת מדד העוצמה. מדד זה מראה לנו אם הקשר בין המשתנים הוא באמת חזק ומשמעותי או שהוא סתם מקרי. כאשר הערך של המדד גדול מ-1, הדבר אומר שיש קשר חיובי ומובהק.

כדי להציג את התוצאות בצורה המדויקת ביותר כפי שהופקו בתוכנה, מצורף צילום מסך מלא מתוך פלט התוכנה המציג את החוקים המובילים שנמצאו:

```
Best rules found:
1. Compromised Immune System=No 71328 ==> Family History of Cancer=No 63831 <conf:(0.89)> lift:(1) lev:(-0) [-51] conv:(0.99)
2. Chronic Sun Exposure=No 63292 ==> Family History of Cancer=No 56636 <conf:(0.89)> lift:(1) lev:(-0) [-49] conv:(0.99)
3. Tobacco Use=Yes 63152 ==> Family History of Cancer=No 56509 <conf:(0.89)> lift:(1) lev:(-0) [-50] conv:(0.99)
4. Unexplained Bleeding=No 63132 ==> Family History of Cancer=No 56491 <conf:(0.89)> lift:(1) lev:(-0) [-51] conv:(0.99)
5. Family History of Cancer=No 71472 ==> Compromised Immune System=No 63831 <conf:(0.89)> lift:(1) lev:(-0) [-51] conv:(0.99)
6. Tobacco Use=Yes 63152 ==> Compromised Immune System=No 56396 <conf:(0.89)> lift:(1) lev:(-0) [-50] conv:(0.99)
7. Chronic Sun Exposure=No 63292 ==> Compromised Immune System=No 56516 <conf:(0.89)> lift:(1) lev:(-0) [-55] conv:(0.99)
8. Unexplained Bleeding=No 63132 ==> Compromised Immune System=No 56358 <conf:(0.89)> lift:(1) lev:(-0) [-70] conv:(0.99)
9. Family History of Cancer=No 71472 ==> Chronic Sun Exposure=No 56636 <conf:(0.79)> lift:(1) lev:(-0) [-49] conv:(1)
10. Compromised Immune System=No 71328 ==> Chronic Sun Exposure=No 56516 <conf:(0.79)> lift:(1) lev:(-0) [-55] conv:(1)
```

ד. דיווח תוצאות האלגוריתם:

מהחוקים שהתקבלו בסעיף הקודם, אפשר לראות שיש קשר ברור בין התנהגויות סיכון לבין אבחון של סרטן הפה. למשל, רואים שאצל מטופלים שמעשנים וצורכים אלכוהול יש סבירות גבוהה לאבחון המחלה.

בנוסף, מדד העוצמה של החוקים האלה גדול מאוד. זה מוכיח לנו מבחינה סטטיסטית שהקשר הוא לא סתם מקרי, אלא שההרגלים האלו באמת קשורים להופעת המחלה ומעלים את הסיכון.

ה. ניתוח מסקנות

כשמסתכלים על התוצאות, אפשר לראות בבירור שיש כמה גורמים עיקריים שמשפיעים על הסיכוי לחלות בסרטן הפה.

הגורם הכי בולט קשור לגיל - רוב מקרי התחלואה שייכים לקבוצת הגיל המבוגרת יותר (הקבוצה שיצרנו כשחילקנו את הגילאים ל-2 סלים בהתחלה), בזמן שאצל הצעירים יש הרבה פחות חולים. זה מראה שהגיל הוא באמת גורם סיכון מרכזי.

עוד משהו שרואים כמעט אצל כל החולים זה השילוב של עישון ושתיית אלכוהול יחד. אצל האנשים הבריאים רואים את השילוב הזה הרבה פחות, מה שמחזק את המסקנה שזה גורם ממש משמעותי שקשור למחלה.

בנוסף, גם היגיינת הפה משפיעה: הנתונים מראים שלרוב החולים יש היגיינת פה פחות טובה, לעומת הבריאים שמקפידים על זה יותר.

חוץ מזה, יש גם קשר לתזונה - הרבה מהחולים לא צורכים מספיק פירות וירקות, בניגוד לבריאים שיש להם תזונה טובה ומאוזנת יותר. זה מראה כמה תזונה נכונה ואורח חיים בריא חשובים כדי להקטין את הסיכון.

2. ניתוח אשכולות

א. הגדרת מדדי איכות לאשכולות- כדי לדעת אם החלוקה לאשכולות שביצענו היא באמת טובה ואיכותית, מקובל להסתכל על שני מדדים עיקריים:

1. הומוגניות ושלמות: הרעיון הוא שמצד אחד, אנחנו רוצים שכל הרשומות בתוך אותו אשכול יהיו כמה שיותר דומות אחת לשנייה. מצד שני, אנחנו רוצים שהאשכולות עצמם יהיו כמה שיותר שונים ורחוקים אחד מהשני. ככל שההבדל בין הקבוצות ברור יותר, והקשר בתוך כל קבוצה חזק יותר, החלוקה נחשבת למוצלחת יותר.

2. משמעות ומגמתיות: חלוקה טובה היא לא רק מתמטית, אלא כזו שמלמדת אותנו משהו חדש. אם האלגוריתם מציג לנו חלוקה טריוויאלית (כמו דברים מובנים מאליהם), זה פחות תורם. מדד איכות מרכזי הוא האם החלוקה מצליחה לחשוף דפוסים נסתרים, קשרים לא אקראיים, או תובנות מעניינות שלא ידענו עליהן לפני הפעלת המודל.

ב. בחירת הגישה לניתוח אשכולות

K-MEANS לצורך ניתוח האשכולות בפרויקט בחרתי להשתמש באלגוריתם

דרך תוכנת ווקה בחרתי לעבוד דווקא עם התוכנה הזו כי היא יודעת לקבוע בעצמה את מרכזי האשכולות ההתחלתיים באופן אוטומטי ומקלה על התהליך.

במהלך העבודה הגדרתי מראש את מספר האשכולות המבוקש. האלגוריתם שייך כל רשומה ממאגר הנתונים למרכז האשכול הקרוב אליה ביותר על בסיס חישובי מרחק כמו מרחק אוקלידי או מנהטן. הפעולה הזו חזרה על עצמה והמרכזים התעדכנו עד שהגענו לשלב ההתכנסות, שבו המרכזים פשוט התייצבו והפסיקו לזוז.

הסיבה העיקרית שבחרתי באלגוריתם הזה היא היותו מודל לא ליניארי, מה שמאפשר לו גמישות רבה והתמודדות טובה עם סוגים שונים של נתונים והתפלגויות. חשוב לציין כחיסרון שיש סיכוי מסוים שהאלגוריתם ייתקע במינימום מקומי ולא ימצא את הפתרון המושלם ביותר, אבל לרוב הוא מפיק תוצאות יעילות וטובות שמתאימות מאוד למטרות הניתוח הזה.

ג. הכנת הנתונים: לפני הפעלת האלגוריתם היה צורך לבצע כמה התאמות בבסיס הנתונים מכיוון שאלגוריתם זה מבוסס על חישובי מרחקים מתמטיים.

הפעולות שביצעתי הן: ביטול הדיסקרטיזציה של משתנה הגיל כלומר החזרתו למספרים רציפים כדי שהאלגוריתם יוכל למדוד במדויק פערי גילאים. הפיכה לבינארי כלומר המרת כל המשתנים הקטגוריאליים לערכים מספריים של אפס ואחת כדי שניתן יהיה לחשב את המרחק שלהם בקלות. נרמול הנתונים כלומר כיווץ כל הערכים במאגר לסולם אחיד בין אפס לאחת.

פעולה זו קריטית כדי שמשתנים בעלי טווח מספרים גדול כמו הגיל לא ישתלטו על חישוב המרחק ויעלימו לחלוטין את השפעתם של משתנים קטנים יותר.

קביעת מספר האשכולות ופרמטרים נוספים:

בחרתי לחלק את הנתונים לשני אשכולות בלבד. הסיבה לבחירה זו היא כדי להתאים את מספר האשכולות למספר הערכים של משתנה המטרה שלנו סרטן הפה, שמכיל שני ערכים של כן או לא. בחירה זו מאפשרת לנו לבדוק האם האלגוריתם יצליח לחלק את האנשים לשתי קבוצות שבאמת משקפות את קבוצת החולים לעומת קבוצת הבריאים.

בנוסף למספר האשכולות שאר הפרמטרים שהגדרתי היו פונקציית המרחק שעבורה בחרתי להשתמש במרחק אוקלידי, ונקודת ההתחלה האקראית שעבורה השארתי את ערך ברירת המחדל של התוכנה מכיוון שהניב תוצאות טובות ויציבות.

ד. תוצאות האלגוריתם

בסעיף זה אציג את התוצאות שהתקבלו מהרצת אלגוריתם החלוקה לשני אשכולות, תוך שימוש בצילומי המסך מפלט התוכנה. להלן ההסבר על כל שלב ועל התוצאות המופיעות בקבצים השונים:

הקובץ הבא מציג את נתוני תהליך ההתכנסות של האלגוריתם. מתוך הפלט ניתן לראות שהתוכנה נזקקה ל 5 איטרציות בלבד כדי להגיע לחלוקה הסופית שבה מרכזי האשכולות התייצבו. מדד השגיאה הפנימית, המייצג את סכום ריבועי המרחקים, עומד בהרצה זו על 311428.

```
kMeans
=====

Number of iterations: 5
Within cluster sum of squared errors: 311428.0340732811

Initial starting points (random):

Cluster 0: 0,0,0,0,0,0,0,0,0,0,0,0,0,1,0,0,0,0,0,0.372093,1,0,1,1,0,0,1,0,1,0,0,0,1,0,0,1,1
Cluster 1: 0,0,0,0,0,0,0,0,0,0,0,0,0,1,0,0,0,0,0,0.662791,1,1,0,1,0,0,0,1,0,0,0,0,1,1,1,1,1
```

הקובץ הבא מציג את החלוקה המרכזית שהתקבלה ואת השגיאה מול משתנה המטרה. התוכנה חילקה את המאגר לאשכול אפס המכיל 48086 רשומות שהן 60 אחוז מהמאגר, ולאשכול אחת המכיל 31716 רשומות שהן 40 אחוז מהמאגר. כאשר התוכנה השוותה את החלוקה הזו למשתנה המחלה של סרטן הפה, התקבלה שגיאת סיווג גבוהה של 49.995 אחוז, כלומר חוסר התאמה כמעט מוחלט.

Weka Explorer

Preprocess Classify **Cluster** Associate Select attributes Visualize

Clusterer Choose **SimpleKMeans** -init 0 -max-candidates 100 -periodic-pruning 10000 -min-density 2.0 -t1 -1.25 -t2 -1.0 -N 2 -A "weka.core.EuclideanDistance -R first-last" -I 500 -num-slo

Cluster mode

☐ Use training set

☐ Supplied test set Set...

☐ Percentage split % 66

☒ Classes to clusters evaluation

(Nom) Oral Cancer (Diagnosis) v

☒ Store clusters for visualization

Ignore attributes

Start Stop

Result list (right-click for options)

19:41:33 - SimpleKMeans

19:48:39 - SimpleKMeans

Clusterer output

		0.1062	0.106	0.1065
Compromised Immune System=Yes				
Oral Lesions=Yes		0.3084	0.3076	0.3095
Unexplained Bleeding=Yes		0.2089	0.2069	0.2118
Difficulty Swallowing=Yes		0.2584	0.2576	0.2596
White or Red Patches in Mouth=Yes		0.3574	0.3572	0.3578
Early Diagnosis=Yes		0.5579	0.5576	0.5582

Time taken to build model (full training data) : 0.31 seconds

=== Model and evaluation on training set ===

Clustered Instances

		48086 (60%)
0		
1		31716 (40%)

Class attribute: Oral Cancer (Diagnosis)

Classes to Clusters:

	0	1	<-- assigned to cluster
24059 15870			No
24027 15846			Yes

Cluster 0 <-- No

Cluster 1 <-- Yes

Incorrectly clustered instances : 39897.0 49.995 %

Status

הקובץ הבא מציג פלט של חלוקה מתוך הרצה נוספת שביצעתי לשם השוואה.

בהרצה זו ניתן לראות שהאשכולות התחלקו בדיוק חצי חצי, כלומר 50 אחוז לכל אשכול עם כ 39900 רשומות בכל אחד. צירפתי זאת כדי להראות את השפעת הפרמטרים השונים והרגישות של התוכנה, שמסוגלת להפיק חלוקות מגוונות על אותו בסיס נתונים.

Weka Explorer

Preprocess Classify **Cluster** Associate Select attributes Visualize

Clusterer Choose **SimpleKMeans** -init 0 -max-candidates 100 -periodic-pruning 10000 -min-density 2.0 -t1 -1.25 -t2 -1.0 -N 2 -A "weka.core.EuclideanDistance -R first-last" -I 500 -num-slo

Cluster mode

☒ Use training set

☐ Supplied test set Set...

☐ Percentage split % 66

☐ Classes to clusters evaluation

(Nom) Oral Cancer (Diagnosis) v

☒ Store clusters for visualization

Ignore attributes

Start Stop

Result list (right-click for options)

19:41:33 - SimpleKMeans

Clusterer output

		0.4594	0.4591	0.4598
Age				
Gender=Male		0.7016	0.7016	0.7016
Tobacco Use=No		0.2086	0.2098	0.2075
Alcohol Consumption=No		0.4049	0.404	0.4057
HPV Infection=No		0.6924	0.6915	0.6934
Betel Quid Use=Yes		0.2906	0.2896	0.2916
Chronic Sun Exposure=Yes		0.2069	0.2075	0.2063
Poor Oral Hygiene=No		0.5018	0.4995	0.5042
Diet (Fruits & Vegetables Intake)=Low		0.3974	0.3975	0.3974
Diet (Fruits & Vegetables Intake)=High		0.2063	0.2081	0.2046
Diet (Fruits & Vegetables Intake)=Moderate		0.3962	0.3945	0.398
Family History of Cancer=Yes		0.1044	0.1041	0.1047
Compromised Immune System=Yes		0.1062	0.1045	0.1078
Oral Lesions=Yes		0.3084	0.3089	0.3078
Unexplained Bleeding=Yes		0.2089	0.2091	0.2087
Difficulty Swallowing=Yes		0.2584	0.2591	0.2577
White or Red Patches in Mouth=Yes		0.3574	0.3563	0.3585
Early Diagnosis=Yes		0.5579	0.5576	0.5581
Oral Cancer (Diagnosis)		No	No	Yes

Time taken to build model (full training data) : 0.41 seconds

=== Model and evaluation on training set ===

Clustered Instances


		39929 (50%)
0		
1		39873 (50%)

הקובץ הבא מציג את טבלת מרכזי האשכולות.

זהו החלק החשוב ביותר להבנת התוצאות לעומק, שכן הטבלה מראה את הערך הממוצע של כל תכונה בתוך כל אשכול. מתוך המספרים המופיעים בטבלה זו אפשר להבין במדויק מהם המאפיינים העיקריים של האנשים ששובצו לכל קבוצה.

Attribute	Cluster#		
	Full Data (79802.0)	0 (48086.0)	1 (31716.0)
Country=Italy	0.0566	0.0566	0.0566
Country=Japan	0.0378	0.0367	0.0393
Country=UK	0.0576	0.0567	0.0588
Country=Sri Lanka	0.0939	0.0945	0.0922
Country=South Africa	0.0369	0.0364	0.0373
Country=Taiwan	0.0925	0.0926	0.0924
Country=USA	0.0575	0.0578	0.0571
Country=Germany	0.0575	0.0576	0.0574
Country=France	0.0563	0.0575	0.0551
Country=Australia	0.0381	0.0388	0.0373
Country=Brazil	0.0559	0.0558	0.0560
Country=Pakistan	0.0936	0.0939	0.0933
Country=Kenya	0.0378	0.0382	0.0373
Country=Russia	0.0554	0.0547	0.0561
Country=Nigeria	0.0388	0.0388	0.0388
Country=Egypt	0.039	0.0394	0.0386
Country=India	0.0949	0.0941	0.0956
Gender=Male	0.4594	0.4595	0.4593
Tobacco Use=No	0.7016	0.7009	0.7023
Alcohol Consumption=No	0.2086	0.2081	0.2091
HPV Infection=No	0.4049	0.4061	0.4037
Betel Quid Use=No	0.6924	0.6913	0.6934
Chronic Sun Exposure=Yes	0.2906	0.2912	0.2899
Poor Oral Hygiene=No	0.2069	0.2066	0.2071
Low Fruits & Vegetables Intake=Low	0.5018	0.5021	0.5015
High Fruits & Vegetables Intake=High	0.3974	0	0
Moderate Fruits & Vegetables Intake=Moderate	0.2063	0.3424	0
Family History of Cancer=Yes	0.3962	0.6576	0
Compromised Immune System=Yes	0.1044	0.1044	0.1044
Oral Lesions=Yes	0.1062	0.106	0.1064
Unexplained Bleeding=Yes	0.3084	0.3076	0.3092

הקובץ הבא מציג את החלוקה לאשכולות באופן ויזואלי וצבעוני. הגרפים מראים את התפלגות הנתונים בין שני האשכולות, המיוצגים בצבעים כחול ואדום. באמצעות תצוגה זו קל לראות בעין אילו תכונות נשאו מעורבות באופן יחסי, ואילו תכונות פוצלו בצורה ברורה וחד משמעית בין שתי הקבוצות.



ה. ניתוח התוצאות והסקת מסקנות

מניתוח התוצאות שהתקבלו ניתן לראות כי האלגוריתם לא הצליח להגיע לביצועי סיווג טובים. שיעור השגיאות היה קרוב ל-50%, כלומר כמעט מחצית מהמקרים סווגו באופן שגוי. תוצאה זו מצביעה על כך שהמודל מתקשה לזהות דפוסים משמעותיים בנתונים, ובפועל ביצעו דומים לניחוש אקראי.

ממצא זה תואם את המסקנות שעלו כבר בממ"ן 21, שלפיהן איכות בסיס הנתונים מוגבלת וקיימת חולשה בקשרים שבין מאפייני הנבדקים לבין משתנה המטרה. כאשר אין קשרים חזקים וברורים בין המשתנים לבין קיום המחלה, יכולת החיזוי של האלגוריתם נפגעת באופן משמעותי.

בנוסף, ניתן לראות כי האלגוריתם יצר שני אשכולות שאינם שווים בגודלם. האשכול הראשון כלל כ-60% מהרשומות, בעוד שהאשכול השני כלל כ-40% מהרשומות. למרות חלוקה זו, כאשר בוחנים את התפלגות משתנה המחלה בתוך כל אחד מהאשכולות, מתברר כי שיעור החולים והבריאים דומה מאוד בשניהם. כלומר, האשכולות שנוצרו אינם מבדילים בין אנשים חולים לבין אנשים בריאים.

ניתוח מעמיק יותר של תוצאות האשכולות מראה כי החלוקה שביצע האלגוריתם התבססה בעיקר על משתנה הרגלי התזונה, שהיה אחד המשתנים הבודדים שיצרו הבדל ברור בין הרשומות. כתוצאה מכך, האלגוריתם קיבץ את הנבדקים בהתאם למאפיין זה, אך לא הצליח ליצור הפרדה משמעותית המבוססת על מצבם הבריאותי.

לסיכום, תוצאות הניתוח מצביעות על כך שבסיס הנתונים אינו מכיל דפוסים חזקים מספיק המאפשרים הבחנה יעילה בין חולים לבריאים. האשכולות שנוצרו אינם משקפים קבוצות שונות מבחינת התחלואה, ולכן אינם תורמים לחיזוי המחלה. ממצאים אלה מחזקים את המסקנה כי מאגר הנתונים הנוכחי מוגבל ביכולתו לתמוך בבניית מודל חיזוי מדויק ואמין.

3. רשת נוירונים מלאכותית

א. הגדרת ארכיטקטורת הרשת:

ארכיטקטורת הרשת בעצם מגדירה את המבנה הפיזי שלה, כמה שכבות יש, כמה נוירונים בכל שכבה, ואיך המידע זורם ביניהם. תכנון המבנה דורש איזון עדין. אם נבנה רשת עמוקה ומורכבת מדי, תהליך הלמידה יהיה מסורבל ואנחנו עלולים להגיע למצב של למידת יתר שבו הרשת פשוט משננת את הנתונים. מצד שני, רשת דלה וקטנה מדי תפספס את התבניות הנסתרות בנתונים ותניב אחוזי שגיאה גבוהים.

לכן, החלטתי לעבוד עם רשת רדודה בתצורה של הזנה קדמית. בתצורה זו, המידע זורם תמיד בכיוון אחד משכבת הקלט, דרך השכבה החבויה, ועד לשכבת הפלט, ללא חזרות אחורה וללא לולאות.

הרשת שלי מורכבת משלוש שכבות: ראשית- שכבת קלט, אשר מכילה נוירונים כמספר התכונות הרלוונטיות במאגר הנתונים שלי, כלומר כל עמודות המאפיינים שמשתתפות בניתוח.

שנית- שכבה חבויה, בחרתי להשתמש בשכבה אחת בלבד הממוקמת באמצע. בהתאם לכלל האצבע המקובל שנועד לשמור על יעילות חישובית ולא לחרוג מעשירית ממספר הדוגמאות, הגדרתי ששכבה זו תכיל בדיוק עשרה נזירונים. עשיתי זאת על ידי שינוי ההגדרה בתוכנה לעשר במקום ערך ברירת המחדל. שלישית- שכבת פלט, השכבה הסופית שמפיקה את התחזית. היא מכילה שני נזירונים בלבד, בהתאמה לשתי המחלקות של משתנה המטרה שלנו, כלומר מאובחן כחולה במחלה או לא.

פונקציית ההפעלה שנבחרה עבור הנזירונים היא פונקציית Sigmoid, שהיא פונקציית ברירת המחדל בתוכנה, והיא מצוינת לבעיות של סיווג לשתי קבוצות. חישוב מספר הפרמטרים ברשת: כדי לחשב את סך כל הפרמטרים, כלומר הקווים שמחברים בין הצמתים בתוספת ערכי ההטיה, נשתמש בנוסחה פשוטה. מחשבים את החיבורים בין הקלט לשכבה החבויה, ומוסיפים את החיבורים בין השכבה החבויה לפלט. על פי כלל האצבע, מספר זה חייב להיות קטן מעשירית מכמות הדוגמאות שיש לנו בנתוני האימון, וכך אכן מתקיים במודל שבנינו.


ב. הגדרת פרמטרי האופטימיזציה

מטרת תהליך האופטימיזציה היא לגרום לרשת לתקן את עצמה בכל פעם שהיא טועה בסיווג, וכך לקרב את פונקציית השגיאה שלה למינימום האפשרי. הפונקציה המקובלת למדידת השגיאה היא טעות ריבועית ממוצעת. כדי לנהל את תהליך הלמידה, הגדרתי מספר פרמטרים: גודל האצווה: כדי לא להעמיס על זיכרון המחשב, הרשת לא רואה את כל הנתונים בבת אחת. הפרמטר מגדיר כמה רשומות יעברו ברשת לפני שהיא תעצור כדי לעדכן ולתקן את המשקולות שלה. השארתי את ברירת המחדל של 100 רשומות בכל קבוצה. תקופת אימון: מסמלת ריצה אחת שלמה שבה כל הרשומות במאגר עברו דרך הרשת. הגדרתי למודל לרוץ במשך 500 פעמים, כדי לאפשר לו מספיק זמן לתקן את עצמו ולהתכנס.


קצב הלמידה: פרמטר המגדיר את גודל הצעד שהרשת עושה בכל פעם שהיא מתקנת שגיאה. קצב למידה קטן יגרום לרשת ללמוד לאט אך בצורה מדויקת יותר, בעוד קצב מהיר עלול לגרום לה לפספס את הפתרון האופטימלי. השארתי את ברירת המחדל של התוכנה שעומדת על 0.3.

ג.

באיור הבא מוצג מבנה רשת הנזירונים שנבנתה בווקה ניתן לראות את שכבות הרשת ואת הקשרים בין משתני הקלט השונים, כגון גיל, מדינה והרגלי חיים, לבין משתנה המטרה – קיום או היעדר סרטן בחלל הפה. התרשים מאפשר להמחיש את אופן זרימת המידע ברשת במהלך תהליך הלמידה.




מתוצאות ההרצה ניתן לראות כי המודל הצליח לסווג נכון כ-49.8% מהמקרים. אחוז דיוק זה נחשב נמוך יחסית ומעיד על כך שהרשת התקשתה למצוא קשרים משמעותיים בין המשתנים שבמאגר לבין המשתנה הנחזה. גם בחינת מטריצת הבלבול מראה שהמודל לא הצליח להבחין בצורה טובה בין שתי המחלקות, ולכן ביצעו אינם מספקים לצורך חיזוי אמין.



הגרף הבא מציג את השינוי בערך השגיאה לאורך מחזורי האימון של הרשת. ניתן לראות שהשגיאה יורדת בהדרגה ככל שמספר מחזורי האימון גדל, דבר המעיד על כך שהרשת אכן לומדת מהנתונים. עם זאת, קצב הירידה בשגיאה אינו חד במיוחד, ובסיום האימון

השגיאה עדיין נשארת ברמה יחסית גבוהה. ממצא זה תואם את ביצועי המודל ומחזק את ההנחה שהנתונים עצמם אינם מאפשרים בניית מודל חיזוי מדויק.

(ניסיתי לעשות את הגרף באקסל ללא הצלחה לכן נעזרתי בAla לציור הגרף)



ד. לאחר בחינת טבלת הבלבול ניתן לראות שהמודל התקשה לזהות דפוסי סיווג ברורים. בפועל, הוא סיווג כמעט את כל הנבדקים כחולים ורק מספר קטן מאוד של מקרים סווג כבריאים. כתוצאה מכך, מרבית האנשים הבריאים במאגר סווגו בטעות כחולים, מה שהוביל לכמות גדולה של תוצאות חיוביות שגויות (False Positives) נראה כי המודל העדיף לבא את המחלקה השכיחה יותר במטרה לצמצם את השגיאה הכוללת, אך הדבר פגע משמעותית ביכולת שלו להבחין בין חולים לבריאים.

ה. מהתוצאות שהתקבלו ניתן להסיק כי הנתונים הקיימים במאגר אינם מספקים מידע שמאפשר חיזוי מוצלח של המחלה. למרות שנבנתה רשת ניורונים בעלת מספר שכבות נסתרות והרשת אומנה במשך מאות איטרציות, רמת הדיוק נשארה סביב 50%, כלומר ביצועים הדומים לניחוש אקראי. נראה שהמודל לא הצליח ללמוד קשרים משמעותיים בין המשתנים המתארים הרגלי חיים ותזונה לבין קיומה של המחלה. ממצאים אלו מחזקים את ההנחה שלצורך חיזוי רפואי אמין נדרש מידע רפואי וקליני נוסף, כגון בדיקות מעבדה, ממצאים רפואיים או נתונים קליניים אחרים, מעבר לנתונים המבוססים על שאלונים והרגלי חיים בלבד.

שאלה 4 סיכום ומסקנות

סיכום התוצאות מממן 21 וממן 22:

בממן 21 המטרה שלנו הייתה למידה מונחית. ניסינו לחזות מי יחלה בסרטן הפה באמצעות מודלים של עצי החלטה. לאחר שניקינו את הנתונים והסרנו עמודות שגורמות לזליגת מידע, גילינו שהמודלים הגיעו לרמת דיוק של סביב 50 אחוזים בלבד. מדדי השגיאה הראו שהסיווג שקול למעשה לניחוש מקרי. המסקנה שם הייתה שהתכונות הרפואיות במאגר חלשות מאוד ולא באמת מסוגלות לנבא את המחלה.

בממן הנוכחי, ממן 22, ניגשנו לאותו בסיס נתונים אבל מזוויות אחרות ובשיטות שונות: תחילה חקרנו חוקי קשר כדי לנסות למצוא שילובים של הרגלים שמופיעים יחד אצל חולים. לאחר מכן השתמשנו בניתוח אשכולות, שהוא מודל של למידה בלתי מונחית. ראינו באופן מובהק שהאלגוריתם התעלם לחלוטין ממשתנה המחלה כיוון שהוא לא מצא בו שום חוקיות. במקום זאת, הוא חילק את האנשים לשתי קבוצות אך ורק על בסיס הרגלי התזונה שלהם, מה שהוביל שוב לשגיאת סיווג של קרוב ל 50 אחוזים מול משתנה המחלה. לבסוף, בנינו רשת נירונים מלאכותית בניסיון לתפוס קשרים מורכבים ולא ליניאריים, אך ראינו שנדרש כוונן זהיר מאוד של פרמטרים כמו קצב למידה כדי לנסות להפיק תובנות מנתונים כל כך רועשים ללא התאמת יתר.

המסקנות הסופיות מהפרויקט כולו:

המסקנה העיקרית והחשובה ביותר משתי העבודות יחד היא שהאלגוריתמים השונים שבהם השתמשנו עובדים בצורה מצוינת, אך בסיס הנתונים עצמו הוא באיכות ירודה ואינו מתאים למטרת החיזוי שהוגדרה.

המודלים השונים, מונחים ובלתי מונחים כאחד, הוכיחו פעם אחר פעם שאין במאגר הזה קשר סטטיסטי חזק או תבנית אמיתית בין ההרגלים והתכונות שנאספו לבין אבחון מחלת הסרטן. כפי שנהוג לומר בעולם כריית המידע, נתונים גרועים יוצרים מודל גרוע. המערכת עושה כמיטב יכולתה, אך אינה יכולה לייצר יש מאין.

כדי לבנות מערכת חיזוי שבאמת תעזור לרופאים בעולם האמיתי לאבחן מחלות בצורה מדויקת, חייבים לאסוף בסיס נתונים איכותי ורלוונטי הרבה יותר. בסיס נתונים כזה צריך לכלול למשל תוצאות של בדיקות דם, ביופסיות, מדדים גנטיים או מדדים קליניים מובהקים, ולא להסתמך רק על שאלונים כלליים של הרגלי חיים כמו שיש במאגר הנוכחי.